

Protokoll Abgabe 2

| Datenbereinigung

Viele der Felder enthalten einen überflüssigen Punkt am Ende, dieser wird zuallererst einmal entfernt. Damit sind alle Felder schon mal gültige numerische Werte.

Es fällt auf, dass ein Farbintensitätswert eine viel höhere Präzision hat als alle anderen Werte. Als nächstes werden also alle Werte einheitlich auf zwei Nachkommastellen gerundet.

Zuletzt ist in einer Reihe noch ein Farbwert von 906, was sich von den anderen Farbwerten welche zwischen 0 und 2 liegen drastisch unterscheidet und daher höchstwahrscheinlich ein Fehler ist. Da sich nicht sicher feststellen lässt ob eigentlich 0.906 oder 1.906 gemeint war, wird die gesamte Reihe aus dem Datensatz entfernt (bzw. sogar alle anderen ähnlich drastischen Outlier die mehr als 100 mal grösser als der Mittelwert ihrer jwlg. Spalte sind theoretisch auch, es gibt aber sonst keine).

| Auswertung

Lineare Regression

Flavanoide scheinen ein guter Indikator für den Proteinwert ($R^2=0.59$, Pearson=0.77), die Menge aller Phenole ($R^2=0.67$, Pearson=0.82) sowie in geringerem Maße auch den Proanthocyaniden ($R^2=0.44$, Pearson=0.66) zu sein.

Ansonsten lassen sich sonst einzelne etwas schwächere Korrelationen feststellen (z.B. Alkohol und Prolinwert mit $R^2=0.41$, Pearson=0.64), die meisten Attribute haben aber wohl recht wenig miteinander zu tun, was in den Scatter Plots auch ersichtlich wird.

K-Means Clustering

Zweidimensionale PCA-Projektion scheint bereits auszureichen, um einen großen Teil der Gesamtvarianz abzudecken. PC 1 erklärt etwa 35.72% der Varianz, PC 2 etwa 18.66%, was insgesamt etwa 54.38% der Gesamtvarianz ausmacht. Die Projektion ist also durchaus schon in zwei Dimensionen aussagekräftig.

Bei Betrachtung des Davies Bouldin Indizes und des Silhouette Coefficients scheint $k=3$ ein Optimum zu sein, da es den niedrigsten (also besten) addierten Rang der beiden Werte besitzt (wobei niedriger = besser bei Davies Bouldin, höher = besser bei durchschnittlichem Silhouettenkoeffizient).

Trotzdem sind bei $k=3$ ein Davies Bouldin Index von 1.422 und ein durchschnittlicher Silhouette Coefficient von 0.278 zu schlecht um auf eine sehr eindeutige Separation hinzuweisen, was sich auch durch recht weit gestreute und sich gegenseitig überschneidende Cluster im Scatter Plot bestätigt. Grob lassen sich die Weine jedoch definitiv nach ihrer chemischen Beschaffenheit in Cluster unterteilen.